

Clasificador de lesiones de piel (HAM10000)

Clasificación de imágenes dermatoscópicas en 7 tipos de lesión de piel, usando transfer learning sobre un CNN pre-entrenado en ImageNet.

⚠ **Demo educativo, no una herramienta de diagnóstico médico.** Ver limitaciones en la sección de Resultados.

Introducción

El cáncer de piel (particularmente el melanoma) es una de las pocas neoplasias donde la detección temprana cambia radicalmente el pronóstico, y donde el diagnóstico depende en gran parte de la inspección visual de la lesión por parte de un especialista. Esto lo convierte en un caso de uso natural para *computer vision*: la señal diagnóstica está codificada en patrones visuales (textura, asimetría, bordes, color) que son difíciles de reducir a un conjunto pequeño de features tabulares diseñadas a mano.

Este es, además, un contraste deliberado con otro proyecto desarrollado en paralelo durante el curso ([VisionDota](#), predicción de resultados de partidas de Dota 2 con datos tabulares), donde un ablation study mostró que ningún modelo de deep learning superó a un XGBoost simple sobre 10 features. La razón es estructural: cuando los datos ya vienen tabulares y las features están correlacionadas entre sí, no hay representación nueva que una red pueda aprender que un modelo de árboles no capture igual de bien. Las imágenes son el caso opuesto — el input son píxeles crudos, sin estructura tabular, y no existe una forma razonable de extraer manualmente las features relevantes para distinguir 7 tipos de lesión. Ahí es donde una CNN, y específicamente el transfer learning desde una red pre-entrenada en un dataset masivo como ImageNet, deja de ser una opción y pasa a ser la herramienta correcta para el problema.

Objetivo de este trabajo: entrenar un clasificador de imágenes dermatoscópicas sobre el dataset público HAM10000, evaluarlo con métricas robustas al desbalance de clases (no solo accuracy), y construir una demo funcional que muestre tanto la predicción como una explicación visual (Grad-CAM) de en qué se basó el modelo — evitando tratarlo como una caja negra.


Metodología

Dataset

[HAM10000](#) — 10,015 imágenes dermatoscópicas, 7 clases:

Clase	Significado	Cantidad
nv	Nevus melanocítico (lunar benigno)	6,705 (67%)
mel	Melanoma	1,113
bkl	Lesión benigna tipo queratosis	1,099
bcc	Carcinoma basocelular	514
akiec	Queratosis actínica / carcinoma intraepitelial	327

Clase	Significado	Cantidad
vasc	Lesión vascular	142
df	Dermatofibroma	115 (1.1%)



Dataset bastante desbalanceado (**nv** es 67% del total) — se maneja con **CrossEntropyLoss** ponderada por clase, no con sobremuestreo, para no introducir duplicados artificiales de las clases raras.

Preprocesamiento y prevención de fuga de datos: el dataset tiene 7,470 lesiones únicas (**lesion_id**) pero 10,015 imágenes — algunas lesiones tienen más de una foto. El split train/valid (80/20) se hace **por lesion_id**, no por imagen, para no repetir la fuga de datos que ya se identificó y corrigió en el proyecto de Dota (ahí era **match_id**, acá es **lesion_id** — mismo principio: nunca dejar que el mismo "sujeto" aparezca en train y en valid a la vez, porque el modelo podría memorizar esa lesión particular en vez de aprender a generalizar).

Arquitectura

ResNet18 pre-entrenado en ImageNet (**torchvision.models.resnet18(weights="DEFAULT")**), con la última capa (**fc**) reemplazada por una capa lineal a 7 clases y fine-tuneado sobre HAM10000 completo (no se congelan capas intermedias). Data augmentation en train (flips horizontales/verticales, rotación, jitter de color) — las fotos dermatoscópicas no tienen una orientación "correcta", así que estas transformaciones son válidas (a diferencia de, por ejemplo, voltear una imagen de texto, donde cambiaría el significado).

Grad-CAM sobre la última capa convolucional (**layer4**) para interpretabilidad: sin esto, el modelo es una caja negra — con esto, se puede verificar si está mirando la lesión o el fondo/pelo/regla de medición, que es exactamente el tipo de sesgo (*shortcut learning*) que suelen aprender estos datasets cuando ciertas clases coinciden con artefactos de la foto (ej. reglas de medición presentes solo en fotos de lesiones ya marcadas como sospechosas).

Entrenamiento y justificación de hiperparámetros

Hiperparámetro	Valor	Justificación
Optimizador	Adam	Estándar para fine-tuning de CNNs; converge más rápido que SGD sin necesitar tanto ajuste de learning rate schedule.
Learning rate	1e-4	Se usa un LR bajo porque el modelo parte de pesos pre-entrenados (ImageNet) — un LR alto destruiría las features ya aprendidas antes de adaptarlas al dominio nuevo.
Weight decay	1e-4	Regularización L2 leve para reducir sobreajuste, dado que el dataset (10k imágenes) es pequeño para el estándar de visión por computadora.
Batch size	32	Balance entre estabilidad del gradiente y memoria disponible en la GPU/MPS local.
Loss	CrossEntropyLoss ponderada por clase inversa a su frecuencia	Sin este ajuste, el modelo colapsa a predecir siempre nv (67% del dataset) y obtiene accuracy alta sin ser útil — la ponderación fuerza a que los errores en clases raras (df , vasc , mel) pesen más en la loss.
Épocas máximas / early stopping	15 épocas, patience=4 sobre valid_loss	Evita sobreajuste: se detiene el entrenamiento si la pérdida de validación no mejora en 4 épocas consecutivas, y se conserva el mejor checkpoint, no el último.
Split train/valid	80/20 por lesion_id , semilla fija (42)	Reproducibilidad y prevención de fuga de datos (ver Metodología → Dataset).

Resultados


Modelo	Accuracy	F1 macro
Baseline: siempre predice nv (clase mayoritaria)	67%	0.11
ResNet18 + transfer learning	78%	0.59

El F1 macro (que pesa todas las clases por igual, no por tamaño) es la métrica que más importa acá: un accuracy de 67% con F1 de 0.11 significa que el baseline "acierta" solo porque **nv** domina el dataset, pero es inútil para las otras 6 clases. El salto a 0.59 de F1 macro es la evidencia real de que el modelo aprendió a distinguir las clases minoritarias, no solo la mayoritaria.

Por clase (validación, split por **lesion_id**):


Clase	Precision	Recall	F1	Soporte
nv	0.92	0.87	0.89	1354

Clase	Precision	Recall	F1	Soporte
bcc	0.65	0.75	0.70	114
bkl	0.66	0.59	0.62	224
mel	0.49	0.56	0.53	232
vasc	0.42	0.95	0.58	20
akiec	0.44	0.38	0.40	56
df	0.29	0.59	0.39	22



La fila de **mel** (melanoma) es la que más importa mirar: 131 aciertos, pero 68 clasificados como **nv** — visualmente confirma la limitación de recall que se discute más abajo.

Interpretabilidad (Grad-CAM)



Fila de arriba: imagen original. Fila de abajo: mismo caso con el mapa de calor Grad-CAM superpuesto (rojo = donde el modelo se fijó más para decidir). En los tres casos el modelo se concentra en la lesión en sí, no en pelos ni en el fondo de piel — es la validación visual de que no está haciendo trampa con atajos espurios del dataset. El tercer caso (melanoma detectado con 99% de confianza) muestra que el modelo sí puede acertar melanomas con seguridad — el problema documentado abajo es específicamente el ~44% que **no** detecta, no que sea incapaz de detectarlos.

La aplicación

La demo (Streamlit) permite subir una foto o usar una imagen de ejemplo del dataset, y muestra la predicción junto con el Grad-CAM y la probabilidad por clase — ver capturas y comandos en el Anexo.

Clasificador de lesiones de piel

Clasificación de imágenes dermatoscópicas en 7 categorías, con transfer learning e interpretabilidad Grad-CAM

Demo educativo de deep learning — no es una herramienta de diagnóstico médico.
El modelo tiene limitaciones reales y conocidas (ver más abajo). Ante cualquier lesión de piel real, consultá a un dermatólogo.

Entrenado sobre HAM10000 (~10,000 imágenes dermatoscópicas, 7 clases) con un ResNet18 pre-entrenado en ImageNet (transfer learning). Accuracy de validación: 78% | F1 macro: 0.59 | Baseline (clase mayoritaria): 67% / 0.11

Subí una foto de la lesión (jpg/png)



Drag and drop file here

Limit 200MB per file • JPG, JPEG, PNG

Browse files

¿NO TENÉS UNA IMAGEN A MANO?

Usar una imagen de ejemplo del dataset

Clasificador de lesiones de piel

Clasificación de imágenes dermatoscópicas en 7 categorías, con transfer learning e interpretabilidad Grad-CAM

Demo educativo de deep learning — no es una herramienta de diagnóstico médico.

El modelo tiene limitaciones reales y conocidas (ver más abajo). Ante cualquier lesión de piel real, consultá a un dermatólogo.

Entrenado sobre HAM10000 (~10,000 imágenes dermatoscópicas, 7 clases) con un ResNet18 pre-entrenado en ImageNet (transfer learning). Accuracy de validación: 78% | F1 macro: 0.59 | Baseline (clase mayoritaria): 67% / 0.11

Subí una foto de la lesión (jpg/png)



Drag and drop file here


Limit 200MB per file • JPG, JPEG, PNG

Browse files


¿NO TENÉS UNA IMAGEN A MANO?

Usar una imagen de ejemplo del dataset

IMAGEN ORIGINAL



GRAD-CAM (ROJO = DÓNDE MIRÓ EL MODELO)



PREDICCIÓN DEL MODELO


Nevus melanocítico (lunar benigno)

Confianza: 88%

Coincide con la etiqueta real

Etiqueta real: Nevus melanocítico (lunar benigno)

PROBABILIDAD POR CLASE



Limitaciones — leer antes de confiar en el resultado

- El recall de melanoma (mel) es de solo 56% en validación — de cada 10 melanomas reales, el modelo deja pasar ~4 como si fueran benignos. Es el error más peligroso posible para un caso de uso real, y no está resuelto.
- Las clases más raras del dataset (df, akiec, vasc) tienen pocos ejemplos (22 a 56 en validación) — sus métricas son ruidosas.
- Entrenado sobre un dataset de origen europeo (HAM10000) — no está validado en otras poblaciones ni tipos de piel.
- Es un modelo de clasificación de imágenes recortadas y centradas en la lesión, no de detección en una foto general del cuerpo.

Limitaciones (leer antes de tomar el resultado en serio)

- **El recall de melanoma es 56%.** De 232 melanomas reales en el set de validación, el modelo clasificó 68 como **nv** (benigno) — el peor error posible para un caso de uso médico real: cáncer marcado como benigno. Esto **no está resuelto** y es la limitación más seria del proyecto.
- Las clases más raras (**df**: 22 casos en validación, **akiec**: 56, **vasc**: 20) tienen métricas ruidosas por el tamaño de muestra chico.
- HAM10000 es un dataset de origen mayormente europeo — no está validado en otros tipos de piel ni poblaciones.
- El modelo clasifica imágenes ya recortadas y centradas en la lesión (como las del dataset) — no hace detección sobre una foto general del cuerpo.
- No se hizo calibración de probabilidades — "60% de confianza" no está verificado que signifique "acierta 6 de cada 10 veces" en la práctica.

Conclusiones y recomendaciones

Conclusión: para clasificación de imágenes médicas, deep learning no es una opción a evaluar entre otras — es la herramienta estructuralmente correcta. El salto de F1 macro de 0.11 (baseline) a 0.59 (ResNet18 + transfer learning) es grande e inequívoco, muy distinto del margen de +0.3 puntos porcentuales que obtuvo deep learning sobre XGBoost en el proyecto de datos tabulares. Transfer learning desde ImageNet fue clave: con solo ~10,000 imágenes (un dataset chico para visión por computadora), entrenar una CNN desde cero habría sido mucho menos efectivo que partir de features visuales ya aprendidas sobre millones de imágenes. La interpretabilidad vía Grad-CAM también resultó esencial — no solo para explicar la predicción, sino para verificar que el modelo no estuviera aprendiendo atajos espurios en vez de la lesión real.

Dicho esto, el modelo **no está listo para ningún uso real**: el recall de melanoma (56%) es la limitación que más importa, porque el costo de un falso negativo en este dominio es clasificar un cáncer como lesión benigna.

Recomendaciones / próximos pasos:

1. **Mejorar el recall de melanoma específicamente** (prioridad más alta, clínicamente): pesos de clase aún más agresivos para **mel**, o un umbral de decisión por clase en vez de simplemente **argmax** sobre las probabilidades.
2. Probar una arquitectura más grande (EfficientNet, ViT) y comparar contra este baseline de ResNet18, para ver si la ganancia justifica el costo computacional adicional.
3. Calibración de probabilidades (reliability diagram) — sin esto, no se puede confiar en el número de confianza que muestra la app.
4. k-fold cross-validation por **lesion_id** para un resultado más robusto que un solo split 80/20.

Anexo: cómo reproducir este trabajo

```
python3 -m venv env_skin
./env_skin/bin/pip install torch torchvision kaggle scikit-learn matplotlib
pillow pandas streamlit
```


Bajar el dataset

Necesita credenciales de Kaggle en `~/.kaggle/kaggle.json` (Kaggle → Settings → API → Create New Token).

```
./env_skin/bin/kaggle datasets download -d kmader/skin-cancer-mnist-ham10000 -p data --unzip
```

(Si el CLI de `kaggle` se cuelga al descargar — nos pasó — bajarlo directo por HTTP con `curl -L -u usuario:key "https://www.kaggle.com/api/v1/datasets/download/kmader/skin-cancer-mnist-ham10000" -o data/ham10000.zip` y descomprimir a mano.)

Entrenar

```
./env_skin/bin/python scripts/train_model.py
```

Correr la web

```
./env_skin/bin/streamlit run app.py
```

Subís una foto (o usás el botón de "imagen de ejemplo" para probar sin tener una propia) y ves la predicción + un mapa de calor Grad-CAM mostrando en qué región de la imagen se basó el modelo.

Regenerar las imágenes del readme

```
./env_skin/bin/python scripts/make_readme_images.py
```

Genera `images/distribucion_clases.png`, `images/predicciones_ejemplo.png` e `images/matriz_confusion.png` a partir del modelo ya entrenado.